

Errata

(Mathematische Einführung in Data Science von Sven-Ake Wegner)

8. August 2024

- Seite 15, Zeile −3 und Seite 16, Zeile 2: $V_{\text{aff}}(\overline{x\mathcal{E}})^{(n)}$
- Seite 17, Zeile 11: r_{xy}
- Seite 24, Zeile −11: $f = \langle (a_1, \dots, a_d), \cdot \rangle + a_0$
- Seite 26, Zeile 18: $f(\cancel{z}) = \text{sig}(\langle w, \cdot \rangle)$
- Seite 31, Zeile 12: ... und $\langle w, \widehat{w}_k \rangle < 0$ gelten.
- Seite 38, Zeile 13: ... und $x_1, \dots, x_k \in D_1 := \{x \mid (x, y) \in D\}$ gelten.
- Seite 38, Zeile 14: $x_1 \in \underset{z \in D_1}{\text{argmin}} \rho(x, z)$ sowie $x_j \in \underset{z \in D_1 \setminus \{x_1, \dots, x_{j-1}\}}{\text{argmin}} \rho(x, z)$ für $j \geq 2$
- Seite 38, Zeile 20: $f(x) \in \underset{y \in Y}{\text{argmax}} N(y)$
- Seite 39, Zeile 4: $z^* \leftarrow \underset{z \in D'_1}{\text{argmin}} \rho(x, z)$
- Seite 39, Zeile 5: $D'_1 \leftarrow D'_1 \setminus \{(z^*, y^*)\}$
- Seite 39, Zeile 10–11: Hierbei bezeichnet $\pi_2(x, y) = x$ die Projektion auf den zweiten Eintrag von $(x, y) \in D$ und y^* das Label von z^* .
- Seite 39, Zeile −2: ... vorgenannten grauen Punkt x mit ...
- Seite 41, Zeile 6–7: ... Trainingsdaten D_{Train} und Testdaten D_{Test} . Dann bestimmt man einen Klassifizierer $f: X \rightarrow Y$ anhand von D_{Train} , und stellt fest, welcher Anteil der Punkte aus D_{Test} durch f korrekt klassifiziert wird.
- Seite 48, Zeile 5–6: ..., dass sich die Texte 1 und 2 deutlich kosinusähnlicher sind als 1 und 3 bzw. 2 und 3.
- Seite 52, Zeile −14: Text D
- Seite 55, Zeile 21–23: ... bevor der minimale Abstand zwischen den Clustern in der nächsten Runde erstmalig über einen einzugebenden Wert $\delta > 0$ wachsen würde.
- Seite 55, Zeile −15: D
- Zeile −12: **while** $\min_{i \neq j} \rho(C_i, C_j) \leq \delta$ **do**
- Seite 56, Zeile 4: ..., wie in Definition 4.2, ...
- Seite 56, Zeile 8: Aufgabe 4.2
- Seite 58, Zeile −16: Der folgende Pseudocode approximiert einen Minimierer der k -means-Kostenfunktion.
- Seite 62, Zeile 5: $\underset{i=1,2}{\text{argmin}} \|x - \mu_i\|$
- Seite 70, Zeile 3–4: Wir wählen $v_1 = \mathbf{1}$ als Eigenvektor zum Eigenwert λ_1 . Dann gelten für Eigenwert und Eigenvektor λ_2 bzw. v_2 ...
- Seite 70, Zeile 7: $v_2 \in \dots$
- Seite 70, Zeile −3: Sei $G = (V, E)$ ein Graph mit $\deg(v) > 0$ für alle $v \in V$.
- Seite 71, Zeile 5: $\emptyset \neq S \subset V$
- Seite 72, Zeilen 6 und 8: $\emptyset \neq S \subset V$
- Seite 73, Zeile 10: Ist G d -regulär (d.h., es gilt $\deg(v) = d$ für alle Vertices $v \in V$ mit einem $d \in \mathbb{N}$), so gilt ...
- Seite 74, Zeile 15: $\emptyset \neq S \subset V$
- Seite 74, Zeile 16: $\text{Cheeg}(G) = \frac{\#\partial S}{\text{vol } S}$
- Seite 87, Zeilen 11 und 14: $\mathbf{A}X$
- Seite 91, Zeile 12: ... Singulärwert von A , ...
- Seite 95, Zeile 6: Ist $1 \leq k < p$ und haben wir $\sigma_{k+1} = \dots = \sigma_p = 0$, ...
- Seite 102, Zeile 17: $r = \text{rk}(A)$

- Seite 106, Zeile 3: $\forall i, j \in \{1, \dots, n\}: \left| \|T_{V_k} a_i - T_{V_k} a_j\| - \|a_i - a_j\| \right| \leq 2 \left(\sum_{\ell=k+1}^r \sigma_\ell \right)^{1/2}$
- Seite 107, Zeile -1 bis Seite 108, Zeile 1:

$$A = \underbrace{\begin{bmatrix} 0.07 & 0.29 & 0.32 & 0.51 & 0.66 & 0.18 & -0.23 \\ 0.13 & -0.02 & -0.01 & -0.79 & 0.59 & -0.02 & -0.06 \\ 0.68 & -0.11 & -0.05 & -0.05 & -0.24 & 0.56 & -0.35 \\ 0.15 & 0.59 & 0.65 & -0.25 & -0.33 & -0.09 & 0.11 \\ 0.41 & -0.07 & -0.03 & 0.10 & -0.02 & -0.78 & -0.43 \\ 0.07 & 0.73 & -0.67 & 0.00 & -0.00 & 0.00 & 0.00 \\ 0.55 & -0.09 & -0.04 & 0.17 & 0.17 & -0.11 & 0.78 \end{bmatrix}}_U \underbrace{\begin{bmatrix} 12.4 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 9.5 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 1.3 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix}}_\Sigma \underbrace{\begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \\ -0.40 & -0.09 & -0.40 & -0.09 & 0.80 \\ -0.41 & -0.09 & -0.40 & -0.09 & -0.80 \\ 0.51 & 0.48 & -0.51 & -0.48 & -0.00 \\ 0.48 & -0.51 & -0.48 & 0.51 & -0.00 \end{bmatrix}}_{V^T}$$

$$= \begin{bmatrix} 0.07 & 0.29 & 0.32 \\ 0.13 & -0.02 & -0.01 \\ 0.68 & -0.11 & -0.05 \\ 0.15 & 0.59 & 0.65 \\ 0.41 & -0.07 & -0.03 \\ 0.07 & 0.73 & -0.67 \\ 0.55 & -0.09 & -0.04 \end{bmatrix} \begin{bmatrix} 12.4 & & \\ & 9.5 & \\ & & 1.3 \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \\ -0.40 & -0.09 & -0.40 & -0.09 & 0.80 \end{bmatrix}.$$

- Seite 108, Zeile 5:

$$\tilde{A} = \begin{bmatrix} 0.15 & 1.97 & 0.15 & 1.97 & 0.56 \\ 0.92 & 0.01 & 0.92 & 0.01 & 0.94 \\ 4.84 & 0.03 & 4.84 & 0.03 & 4.95 \\ 0.36 & 4.03 & 0.36 & 4.03 & 1.20 \\ 2.92 & -0.00 & 2.92 & -0.00 & 2.98 \\ -0.34 & 4.86 & -0.34 & 4.86 & 0.65 \\ 3.92 & 0.02 & 3.92 & 0.02 & 4.00 \end{bmatrix} = \begin{bmatrix} 0.07 & 0.29 \\ 0.13 & -0.02 \\ 0.68 & -0.11 \\ 0.15 & 0.59 \\ 0.41 & -0.07 \\ 0.07 & 0.73 \\ 0.55 & -0.09 \end{bmatrix} \begin{bmatrix} 12.4 & \\ & 9.5 \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \end{bmatrix}$$

- Seite 109, Zeile 16:

$$= [0 \ 1 \ 0 \ \dots \ 0] \begin{bmatrix} 0.07 & 0.29 & \dots & -0.23 \\ 0.13 & -0.02 & & -0.06 \\ 0.68 & -0.11 & & -0.35 \\ 0.15 & 0.59 & & 0.11 \\ 0.41 & -0.07 & & -0.43 \\ 0.07 & 0.73 & & 0.00 \\ 0.55 & -0.09 & \dots & 0.78 \end{bmatrix} \begin{bmatrix} 12.4 & & & \\ & 9.5 & & \\ & & 1.3 & \\ & & & \ddots \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \\ \vdots & & & & \vdots \\ 0.48 & -0.51 & -0.48 & 0.51 & 0.00 \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

- Seite 109, Zeile -2:

$$u_2 = 0.29 \cdot \text{Antje} - 0.02 \cdot \text{Birgit} + \dots - 0.09 \cdot \text{Gül},$$

- Seite 111, Zeile 12:

$$\tilde{A} = \begin{bmatrix} 0.07 & 0.29 \\ 0.13 & -0.02 \\ 0.68 & -0.11 \\ 0.15 & 0.59 \\ 0.41 & -0.07 \\ 0.07 & 0.73 \\ 0.55 & -0.09 \end{bmatrix} \begin{bmatrix} 12.4 & \\ & 9.5 \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \end{bmatrix}$$

Antje →
 Birgit →
 Constanze →
 Dorothee →
 Eleonore →
 Fatema →
 Gül →

 Alien Casablanca StarWars Titanic Matrix
 ↓ ↓ ↓ ↓ ↓
0.56 0.09 0.56 0.09 0.59
-0.12 0.69 -0.12 0.69 0.02

- Seite 110, Zeile 7: $\mathbb{R}_{\mathcal{F}}^5$
- Seite 112, Zeile 5: $(\text{Film})_{\mathcal{F}} \quad \mathbb{R}_{\mathcal{F}} \xrightarrow{A} \mathbb{R}_{\mathcal{B}} \quad (\text{Bewerterin})_{\mathcal{B}}$
- Seite 111, Zeile 4: \mathbf{R} (statt \mathbf{R})
- Seite 112, Zeilen 14 und 25: \mathbf{R} (statt \mathbf{R})
- Seite 112, Zeile -3: ... die Daten ~~erst~~ einem geeigneten Pre- oder Postprocessing zu unterziehen ...
- Seite 125, Zeile -3: $H_d(1)$
- Seite 129, Zeile -1: $0 < \varepsilon < 1$
- Seite 131, Zeile 9: $H_{\delta, x_1} = \{(x_2, \dots, x_d \in \mathbb{R}^{d-1} \mid (x_1, x_2, \dots, x_d) \in H_{\delta})\}$
- Seite 134, Zeile 9: Für solche Zufallsvektoren erhält man ...
- Seite 139, Zeile -1: $\|X^{(i)}\| \approx 1$
- Seite 146, Zeile 5: $P[\|X\| - \sqrt{d} \geq \varepsilon]$
- Seite 164, Zeile -17: ... der Abstand ~~der~~ Mittelpunkte, ...
- Seite 167, Zeile 5-7: ~~Im Fall der Varianz sind diese eher technisch, und wir formulieren daher im Satz für die Varianz nur die sich ergebende qualitative asymptotische Aussage.~~
- Seite 183, Zeile -1: Wenn \mathbf{D} linear trennbar ist, ...

- Seite 186, Zeile 8: ~~—~~ **return** $w^{(j)}$
- Seite 189, Zeile -5: $(x, y) \in D$
- Seite 190, Zeile 14–15: ... die Worte „Bonus“, „Vertrag“, „das“ und „Mensa“ ...
- Seite 193, Zeile 6: $\cdots = \langle w', x_0 - (\langle w', x_0 \rangle + b')w' \rangle + b'$
- Seite 193, Zeile 12: $\geq \|x_0 - x_1\|^2 + 2\langle (\langle w', x_0 \rangle + b')w', x_1 - x \rangle$
- Seite 193, Zeile 13: $= \|x_0 - x_1\|^2 + 2(\langle w', x_0 \rangle + b')\langle w', x_1 - x \rangle$
- Seite 194, Zeilen -2 und -1: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 194, Zeile -1: $h: \mathbb{R}^d \rightarrow \mathbb{R}^{\mathbf{d}}$
- Seite 195, Zeilen 2, 4, 5, 9, 10, 12, 15 und 20: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 196, Zeilen 6–8, 12 und 13: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 198, Zeile 6: $(w^*, b^*) \in M$
- Seite 198, Zeile 11–16: Es folgt also nach **Proposition** 17.14, dass $w_1^* = w_2^* =: w^*$ ist. **Gelte ohne Einschränkung** $b_1^* < b_2^*$. Dann wählen wir für ~~(w^*, b_1^*) und~~ (w^*, b_2^*) **jeweils** ~~i_1 und einen Index i wie in Teil ② und erhalten~~

$$y_i(\langle w^*, x_i \rangle + b_1^*) = \langle w^*, x_i \rangle + b_1^* < \langle w^*, x_i \rangle + b_2^* = 1$$

im Widerspruch dazu, dass (w^*, b_1^*) in M liegt. ~~Ist $b_1^* > b_2^*$, so vertauschen wir die Rollen von i_1 und i_2 .~~

- Seite 198, Zeile -11, -8 und -4: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 200, Zeile 7: $L(x, \theta, \mu) := f(x) - \sum_{i=1}^q \theta_i g_i(x) + \# \sum_{j=r}^q \mu_j h_j(x)$
- Seite 200, Zeile 18: ..., ist x^* ein **Minimierer** des oben angegebenen Optimierungsproblems ...
- Seite 203, Zeile 17: ... ist es möglich, i_0 mit $\lambda_{i_0} \neq 0$...
- Seite 206, Zeile 7: $D_1 = \{(x_i, y_i) \mid i = 1, 6, 7\}$ und $D_2 = \{(x_i, y_i) \mid i = 1, 6, 11\}$
- Seite 206, Zeile 8: **Durch Streichen von Nullen in Beispiel 14.15(i) und Lösung des Optimierungsproblems für D_2 erhalten wir ...**
- Seite 206, Zeile 12: ~~0.349~~ **0.439**
- Seite 207, Zeile 4 (in den Bildern): $D_1 \cdots D_2$
- Seite 207, Zeilen 12 und 13: λ_i^*
- Seite 208, Zeile 13: ... und Satz 14.12(ii) ist [GK02, Satz 2.46].
- Seite 209, Zeile -6: ..., wenn man einen der Punkte x_6^* , x_7^* , oder x_{11}^* weglässt?
- Seite 216, Zeile -14: ..., sodass $y_i(\langle w, x_i \rangle + b) \geq 1$ für ...
- Seite 220, Zeile 16: ... mit $\lambda_{i_0}^* \neq 0$ ist ...
- Seite 220, Zeile 18: ... Wahl von λ^* und ...
- Seite 224, Zeile 6: Haben wir also $\langle f, f \rangle = 0$ ~~für alle $x \in X$~~ , so ist ...
- Seite 224, Zeile -10: ... positive **Semidefinitheit** der Gram-Matrix ...
- Seite 226, Zeile 12: Geben Sie an, welche $x \in \mathbb{R}$ vom **zurückgezogenen** Klassifizierer ...
- Seite 230, Zeile 15: **die Rectified Linear Unit**
- Seite 231, Zeile -4: ... Neuronen aus Proposition 16.2 zusammensetzen
- Seite 232, Zeile 3: ... sonst,
- Seite 232, Zeile 6 – -7: ... ist es manchmal von Vorteil ...
- Seite 236, Zeile 9: B ist die Matrix ohne das $(\cdot)^{-1}$.
- Seite 239, Zeile 15: $\mathcal{F}(f_1 * f_2) = \mathcal{F}f_1 \cdot \mathcal{F}f_2$
- Seite 262, Zeile 1–4: Den Rieszschen Darstellungssatz in der Version 16.19 kann man in [Wer18, Theorem II.2.5] nachlesen, die **andere Version 16.16**, oft auch Riesz-Markov-Theorem genannt, findet man in [Rud87, Theorem 6.19].
- Seite 270, Zeile 14: Dann gilt $h'(t) = \langle \nabla f(y + t(x - y)), x - y \rangle$...

- Seite 270, Zeile 16: $\cdots = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$
- Seite 270, Zeile 18: $\cdots = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle - \langle f(y), x - y \rangle dt$
- Seite 270, Zeile -1: ... mithilfe von **Proposition** 17.4 ...
- Seite 271, Zeile 14: **Folgerung 17.10.** Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ differenzierbar ~~und~~ **konvex**.
- Seite 271, Zeile 18–19: (i) \implies (ii): Aus der Konvexität folg die erste Ungleichung mit **Proposition** 17.4 und ...
- Seite 271, Zeile 20: (ii) \implies (i): Die erste Ungleichung impliziert Konvexität mit **Proposition** 17.4 und ...
- Seite 272, Zeile 16: Aus Lemma 17.9 und **Proposition** 17.4 folgern wir
- Seite 272, Zeile 20: \geq
 \uparrow
Prop. 17.4
- Seite 273, Zeile 10: \leq
 \uparrow
Prop. 17.4
- Seite 275, Zeile -2: Dann gilt ~~wegen~~
- Seite 277, Zeile -10: mit **Proposition** 17.4
- Seite 278, Zeile 8: Dies ist nach **Proposition** 17.4 äquivalent zu
- Seite 278, Zeile 18: Ein Vergleich der Abschätzung in **Proposition** 17.4 zeigt nochmal ...
- Seite 279, Zeile 13: \geq
 \uparrow
Lem. 17.18 u.
Prop. 17.4
- Seite 283, Zeile -9: 4: $x^{(k+1)} \leftarrow x^{(k)} - \gamma_k \nabla f(x^{(k)})$.
- Seite 296, Zeile -14: S. Shalev-Shwartz und S. Ben-David, **Understanding**