Errata

(Mathematische Einführung in Data Science von Sven-Ake Wegner)

23. April 2026

- Seite 10, Zeile -1:
$$\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y}) = \sum_{i=1}^{n} x_i y_i - \overline{y}\sum_{i=1}^{n} x_i - \overline{x}\sum_{i=1}^{n} y_i + n\overline{x}\,\overline{y} = \big(\sum_{i=1}^{n} x_i y_i\big) - n\overline{x}\,\overline{y}.$$
- Seite 11, Zeile -1:
$$0 = \sum_{i=1}^{n}(ax_i+b-y_i) = a\sum_{i=1}^{n} x_i + nb - \sum_{i=1}^{n} y_i = an\overline{x} + nb - n\overline{y},$$
- Seite 13, Zeile 16f: Folglich ergibt sich für feste $y_i \in \mathbb{R}$ und geeignet kleines $\delta > 0$
$$\begin{aligned}\mathrm{P}\big[|Y_i(f)-y_i|<\delta\big] &= \mathrm{P}\big[\mathcal{E}_i \in \big(y_i - f(x_i) - \delta, y_i - f(x_i) + \delta\big)\big] \\ &= \int_{y_i-f(x_i)-\delta}^{y_i-f(x_i)+\delta} \tfrac{1}{\sqrt{2\pi}\sigma}\,\mathrm{e}^{-\frac{(t-0)^2}{2\sigma^2}}\,\mathrm{d}t \\ &= \int_{-\delta}^{\delta} \tfrac{1}{\sqrt{2\pi}\sigma}\,\mathrm{e}^{-\frac{(t+y_i-f(x_i))^2}{2\sigma^2}}\,\mathrm{d}t \\ &\approx \Big(\tfrac{1}{\sqrt{2\pi}\sigma}\,\mathrm{e}^{-\frac{(y_i-f(x_i))^2}{2\sigma^2}}\,\mathrm{d}t\Big)\cdot 2\delta.\end{aligned}$$
  Per Unabhängigkeit folgt
$$\mathrm{P}\big[|Y_i(f)-y_i|<\delta \text{ für alle } i\big] \approx \Big(\prod_{i=1}^{n} \tfrac{1}{\sqrt{2\pi}\sigma}\,\mathrm{e}^{-\frac{(f(x_i)-y_i)^2}{2\sigma^2}}\Big)\cdot(2\delta)^n$$
  Wir stellen uns nun vor …
- Seite 13, Zeile 22: Seitenlänge
- Seite 15, Zeile -10: …konstante Zufallsvariable av.
- Seite 15, Zeile -3 und Seite 16, Zeile 2: V~~ar~~$\overline{(x\mathcal{E})}^{(n)}$
- Seite 15, Zeile -2: $\cdots + \frac{2}{n^2}\sum_{i<j} x_i x_j\,\mathrm{E}(\mathcal{E}_i)\,\mathrm{E}\,\mathcal{E}_j)$
- Seite 16, Zeile 3: da $\overline{x^{(n)2}} = \mathrm{var}(x^{(n)}) + \overline{x^{(n)}}^2$ als Summe …
- Seite 17, Zeile 8: Ist Letzteres der Fall, so ist $\mathrm{sign}(r_{xy}) = \mathrm{sign}(\langle u, v\rangle) = \cdots$
- Seite 17, Zeile 11: r_{xy}
- Seite 18, Zeile -3: …$f^*(x) = \langle a^*, x\rangle + b^*$ …
- Seite 19, Zeile -6: …berechnen wir (mit nur für den Moment $\phi(\tilde{a}) = \langle \tilde{a}, X^{\mathrm{T}} X\tilde{a}\rangle$):
- Seite 25, Zeile -5: Im Bild muss es die z-Achse sein.
- Seite 26, Zeile 9: …und $(w,b) = (w_1,\ldots,w_d,b)$ für …
- Seite 26, Zeile 18: f~~(z)~~ $= \mathrm{sig}(\langle w, \cdot\rangle)$
- Seite 26, Zeile -1: $\mathrm{P}\big[Y_i$~~(f)~~ $= y_i$ fr̈ alle $i\big] = \cdots$
- Seite 27, Zeile 2: $L\colon \big\{f\colon \mathbb{R}^d \to (0,1) \mid f \text{ logistische Funktion}\big\} \to \mathbb{R}$
- Seite 26, Zeile -1: $h'(t) = \mathrm{sig}(t)$~~$+1$~~
- Seite 30, Seite 6: …*überlappen*, wenn für jedes $w \in \mathbb{R}^{d+1}\backslash\{0\}$ ein k existiert, …
- Seite 30, Zeile 9: falls $\mathrm{sig}(\langle w, \widehat{x}\rangle) \geqslant 1/2$
- Seite 31, Zeile 12: …und $\langle w, \widehat{w}_k\rangle < 0$ gelten.
- Seite 35, Zeile -5: $\nabla\ell(x) = \sum_{i=1}^{n}\big(\mathrm{sig}(\langle w, \widehat{x}_i\rangle) - y_i\big)\widehat{x}_i$

- Seite 38, Zeile 13: ... und $x_1, \dots, x_k \in D_1 := \{x \mid (x,y) \in D\}$ gelten.
- Seite 38, Zeile 14: $x_1 \in \operatorname*{argmin}_{z \in D_1} \rho(x,z)$ sowie $x_j \in \operatorname*{argmin}_{z \in D_1 \setminus \{x_1,\dots,x_{j-1}\}} \rho(x,z)$ für $j \geqslant 2$
- Seite 38, Zeile 20: $f(x) \in \operatorname*{argmax}_{y \in Y} N(y)$
- Seite 37, Zeile 1–9:

```
function k-NN Klassifizierer(D, k, x)
    D' ← D,  A ← ∅
    for j ← 1 to k do
        z* ← argmin_{z∈D'} ρ(x, π_1(z))
        A ← A ∪ {z*},  D' ← D' \ {z*}
    for y in Y do
        N(y) ← #{a ∈ A | π_2(a) = y}
    ℓ ← argmax_{y∈Y} N(y)
    return ℓ
```

  Hierbei bezeichnet $\pi_2(x,y) = y$ die Projektion auf den zweiten Eintrag von $(x,y) \in D$ ~~und y^* das Label von z^*~~.
- Seite 39, Zeile −2: ... vorgenannten grauen Punkt x mit ...
- Seite 41, Zeile 6–7: ... *Trainingsdaten* D_{Train} und *Testdaten* D_{Test}. Dann bestimmt man einen Klassifizierer $f\colon X \to Y$ anhand von D_{Train}, und stellt fest, welcher Anteil der Punkte aus D_{Test} durch f korrekt klassifiziert wird.
- Seite 41, Zeile 16: ..., *sowie* $k < n$.
- Seite 41, Zeile 17: *Die Berechnung der k-nächsten Nachbarn von x kann so implementiert werden, dass dabei höchstens $(n \cdot d \cdot k)$-viele Mulitplikationen anfallen.*
- Seite 41, Zeile 21: In der euklidischen Metrik müssen für eine solche Distanz $(d-1)$-viele Multiplikationen ausgeführt werden, wenn wir für die Berechnung des Argmin die Wurzel weglassen. Dies führt auf

$$(d-1) \cdot (n + (n-1) + \dots + (n-k+1)) \leqslant \cancel{C}\, d \cdot k \cdot n$$

  Multiplikationen ~~mit einem geeigneten $C \in \mathbb{N}$~~.
- Seite 42, Zeile 7: ..., wählen wir k-nächste Nachbarn $x_1, \dots, x_k$ von x und bezeichnen mit $y_1, \dots, y_k$ deren Label.
- Seite 42, Zeile 13: $f\colon X \to Y,\ f(x) = \dfrac{\sum_{i=1}^{k} w(x_i, x) \cdot y_i}{\sum_{i=1}^{k} w(x_i, x)}$
- Seite 43, Zeile 11: $\tilde{x}^{(i)} = \left(a + \dfrac{(x_1^{(i)} - \min_{j=1,\dots,n} x_1^{(j)})(b-a)}{\max_{j=1,\dots,n} x_1^{(j)} - \min_{j=1,\dots,n} x_1^{(j)}}, \dots\right)$
- Seite 43, Zeile 13: $\tilde{x}^{(i)} = \left(\dfrac{x_1^{(i)} - \overline{x_1^{(\cdot)}}}{\sigma_1}, \dots\right)$
- Seite 44, Zeile −9: $\rho(x^{(1)}, x^{(4)}) = 3.681$
- Seite 48, Zeile 5–6: ..., dass sich die Texte 1 und 2 deutlich kosinusähnlicher sind als 1 und 3 bzw. 2 und 3.
- Seite 48, Zeile 16: Einige solcher Methoden diskutieren wir in Aufgabe 3.10.
- Seite 48, Zeile 26: ~~Der Kosinusabstand wird hingegen immer kleiner, je öfter das Wort im zweiten Text auftritt.~~ Der Kosinusabstand verhält sich hier natürlicher, weil sich der Skalarprodukt vergrößert, wenn sich die Häufigkeit des fixierte Wortes im zweiten Text erhöht.
- Seite 52, Zeile −14: D
- Seite 54, Zeile 12: Für endliche Teilmengen $A, B \subseteq X$ definieren wir ...

- Seite 55, Zeile 21–23: ... bevor der minimale Abstand zwischen den Clustern in der nächsten Runde erstmalig über einen einzugebenden Wert $\delta > 0$ wachsen würde.
- Seite 55, Zeile 24:

```
function Verknüpfungsbasiertes Clustering (X, ρ, D, δ)
    k ← #D
    for i ← 1 to k do
        C_i ← {x_i}
    while min_{i≠j} ρ(C_i, C_j) ⩽ δ and k ⩾ 2 do
        m ← 0
        (i*, j*) ← argmin_{i≠j} ρ(C_i, C_j)
        for ℓ ← 1 to k − 1 do
            if ℓ = min(i*, j*) then
                C_ℓ ← C_{i*} ∪ C_{j*}
            if ℓ = max(i*, j*) then
                m ← 1
                C_ℓ ← C_{ℓ+m}
            else
                C_ℓ ← C_{ℓ+m}
        k ← k − 1
    return C_1, ..., C_k
```

- Seite 56, Zeile 4: ..., wie in Definition 4.2, ...
- Seite 56, Zeile 8: Aufgabe 4.2
- Seite 56, Zeile −2: $K\colon \mathcal{C}_k \to \mathbb{R}$
- Seite 58, Zeile −16: *Der folgende Pseudocode approximiert einen Minimierer der k-means-Kostenfunktion.*
- Seite 58, Pseudocode:

```
1:  function k-means (D, k, X, ρ)
2:      μ_1, ..., μ_k ← pairwise different points from X
3:      for i ← 1 to k do
4:          C_i ← {x ∈ D | i ∈ argmin_{j=1,...,k} ρ(x, μ_j)}
5:      U ← True
6:      while U = True do
7:          U ← False
8:          for i ← 1 to k do
9:              μ_i ← μ(C_i)
10:         for i ← 1 to k do
11:             C'_i ← {x ∈ D | i ∈ argmin_{j=1,...,k} ρ(x, μ_j)}
12:             if C'_i ≠ C_i
13:                 C_i ← C'_i
14:                 U ← True
15:     return C_1, ..., C_k
```

Hierbei ist in den Zeilen 4 und 9 darauf zu achten, dass man jeweils ein i im Argmin auswählt, falls dieses nicht eindeutig ist.

- Seite 59, Zeile 8:

$$\mu(A) \in \operatorname*{argmin}_{\mu \in A} \sum_{x \in A} \rho(x,\mu)^2 \quad \text{bzw.} \quad \mu(A) \in \operatorname*{argmin}_{\mu \in X} \sum_{x \in A} \rho(x,\mu)$$

- Seite 59, Zeile −5: *Beweis.* Für $j \geqslant 1$ bezeichne $(C_1^{(j)}, \dots, C_k^{(j)})$ das Clustering, welches in der j-ten Runde des Algorithmus definiert wird.

- Seite 59, Zeile −2: $K(C_1^{(j)},\dots,C_k^{(j)}) \quad = \min_{\mu_1,\dots,\mu_k\in X} \sum_{i=1}^{k} \sum_{x\in C_i^{(j)}} \rho(x,\mu_i)^2$
- Seite 60, Zeile 5: ... Zeile 11 von Algorithmus ...
- Dort entspricht Bild 1b der vorletzten Zeile in der Abschätzung und Bild 2a der darüber.
- Seite 60, Zeile 13: weil wir ja gerade wegen $\rho(x_3,\mu_1) < \rho(x_3,\mu_2)$ den Punkt x_3 vom Cluster C_2 in Bild 1b zu Cluster C_1 in Bild 2a verschoben haben.
- Seite 62, Zeile 4: ~~Mittelpunkten~~ Startwerten
- Seite 62, Zeile 5: $\operatorname{argmin}_{i=1,2} \|x-\mu_i\|$
- Seite 64, Zeile 7: ... sondern ~~nur~~ z.B. nur durch eine Liste ...
- Seite 64, Zeile 10: $A = (a_{ij})_{i,j=1,\dots,n}$
- Seite 64, Zeile 12: $L = (\ell_{ij})_{i,j=1,\dots,n}$
- Seite 65, Zeile 11: Wir beginnen mit zwei Beispielen.
- Seite 66, Zeile 2: ... In Beispiel 5.7 ist $\lambda_2 \neq 0$ und es gibt keine Cluster (oder anders ausgedrückt nur ein einziges), in Beispiel 5.8 ...
- Seite 69, Zeile 15: Für die andere Richtung sei $\{v_1,\dots,v_n\}$ eine Basis aus Eigenvektoren zu den λ_i und $U \subseteq \mathbb{R}^n$ ein Unterraum mit $\dim U = n-k+1$. Dann ist aus Dimensionsgründen $U \cap \operatorname{span}\{v_1,\dots,v_k\} \neq \{0\}$ und wir können $0 \neq x = \alpha_1 v_1 + \dots + \alpha_k v_k \in U$ wählen. Dann folgt

$$\frac{\langle x, Mx\rangle}{\langle x,x\rangle} = \frac{\sum_{i=1}^{k} \lambda_i \alpha_i^2}{\sum_{i=1}^{k} \alpha_i^2} \leqslant \frac{\lambda_k \sum_{i=1}^{k} \alpha_i^2}{\sum_{i=1}^{k} \alpha_i^2} = \lambda_k,$$

  weil die λ_i wachsend sind. Damit erhalten wir $\min_{0\neq x\in U} \frac{\langle x,Mx\rangle}{\langle x,x\rangle} \leqslant \lambda_k$ und es folgt

$$\max_{\substack{U\subseteq\mathbb{R}^n \\ \dim U = n-k+1}} \min_{\substack{x\in U \\ x\neq 0}} \frac{\langle x, Mx\rangle}{\langle x,x\rangle} \leqslant \lambda_k.$$

- Seite 70, Zeile 3–4: Wir wählen $v_1 = \mathbb{1}$ als Eigenvektor zum Eigenwert λ_1. Dann gelten für Eigenwert und Eigenvektor λ_2 bzw. v_2 mit $\|v_2\| = 1$ ...
- Seite 70, Zeile 7: $v_2 \in \cdots$
- Seite 70, Zeile −3: Sei $G = (V,E)$ ein Graph mit $\deg(v) > 0$ für alle $v \in V$.
- Seite 71, Zeile 5: $\emptyset \neq S \subset V$
- Seite 72, Zeilen 6 und 8: $\emptyset \neq S \subset V$
- Seite 72, Zeile −4:

$$\lambda_2(\mathcal{L}) = \min_{\substack{x\neq 0 \\ \langle Dx,\mathbb{1}\rangle = 0}} \frac{\sum_{\{i,j\}\in E} (x_i - x_j)^2}{\sum_{i=1}^{n} x_i^2 d_i}.$$

- Seite 73, Zeile 2:

$$\mathcal{L}D^{1/2}\mathbb{1} = D^{-1/2}LD^{-1/2}D^{1/2}\mathbb{1} = D^{-1/2}L\mathbb{1} \underset{\substack{\uparrow \\ \text{Proposition} \\ 5.6}}{=} D^{-1/2}0\mathbb{1} = 0D^{1/2}\mathbb{1}.$$

- Seite 73, Zeile 4:

$$\lambda_2(\mathcal{L}) \underset{\substack{\uparrow \\ \text{Satz} \\ 5.13}}{=} \min_{\substack{x\neq 0 \\ \langle x, D^{1/2}\mathbb{1}\rangle = 0}} \frac{\langle x, \mathcal{L}x\rangle}{\langle x,x\rangle} \overset{(*)}{=} \min_{\substack{y\neq 0 \\ \langle D^{1/2}y, D^{1/2}\mathbb{1}\rangle = 0}} \frac{\langle D^{1/2}y, \mathcal{L}D^{1/2}y\rangle}{\langle D^{1/2}y, D^{1/2}y\rangle}$$

$$= \min_{\substack{y\neq 0 \\ \langle y, D\mathbb{1}\rangle = 0}} \frac{\langle y, Ly\rangle}{\langle y, Dy\rangle} = \min_{\substack{y\neq 0 \\ \langle Dy,\mathbb{1}\rangle = 0}} \frac{\sum_{\{i,j\}\in E}(y_i - y_j)^2}{\sum_{i=1}^{n} y_i^2 d_i}$$

- Seite 73, Zeile 10: Ist G d-regulär (d.h., es gilt $\deg(v) = d$ für alle Vertices $v \in V$ mit einem $d \in \mathbb{N}$), so gilt ...
- Seite 73, Zeile −9: *(ii) Für* $r \leqslant k \leqslant n-1$ *gelten* ...
- Seite 73, Zeile −2:

$$\operatorname{vol} S_k^c - \operatorname{vol} S_{k+1}^c = \sum_{i=k+1}^{n} d_i - \sum_{i=k+2}^{n} d_i = d_{k+1}$$

- Seite 74, Zeile 15: $\emptyset \neq S \subset V$
- Seite 74, Zeile 16: $\operatorname{Cheeg}(G) = \frac{\#\partial S}{\operatorname{vol} S}$
- Seite 74, Zeile 20:

$$\langle Dx, \mathbb{1} \rangle = \sum_{i=1}^{n} d_i x_i = \dots$$

- Seite 75, Zeile 7–8:

$$\begin{aligned} \dots &= \operatorname{vol} S - \operatorname{vol} S \cdot \frac{\operatorname{vol} S}{\operatorname{vol} S + \operatorname{vol} S^c} \\ &\geqslant \operatorname{vol} S - \operatorname{vol} S \cdot \frac{\operatorname{vol} S}{2 \operatorname{vol} S}, \end{aligned}$$

- Seite 75, Zeile −6 (Gleichung (5.2)):

$$\dots \text{ und } \langle Dx, \mathbb{1} \rangle = \sum_{i=1}^{n} d_i x_i = 0$$

- Seite 75, Zeile −5: ..., zu zeigen, dass $\lambda_2 \geqslant \alpha^2/2$ ist, ...
- Seite 76, Zeile 4:

$$\begin{bmatrix} x_1 - x_r \\ \vdots \\ x_{r-1} - x_r \\ 0 \\ x_{r+1} - x_r \\ \vdots \\ x_n - x_r \end{bmatrix} = \begin{bmatrix} x_1 - x_r \\ \vdots \\ x_{r-1} - x_r \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} - \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 0 \\ x_r - x_{r+1} \\ \vdots \\ x_r - x_n \end{bmatrix} =: p - n.$$

- Seite 77, Zeile 4:

$$\begin{aligned} \lambda_2 &= \frac{\sum_{\{i,j\} \in E} (x_i - x_j)^2}{\sum_{i=1}^{n} x_i^2 d_i} \\ &\underset{\substack{\uparrow \\ (5.3) \\ (5.4)}}{\geqslant} \frac{\sum_{\{i,j\} \in E} \left((p_i - p_j)^2 + (n_i - n_j)^2 \right)}{\sum_{i=1}^{n} (p_i^2 + n_i^2) d_i} \\ &= \frac{\sum_{\{i,j\} \in E} (p_i - p_j)^2 + \sum_{\{i,j\} \in E} (n_i - n_j)^2}{\sum_{i=1}^{n} p_i^2 d_i + \sum_{i=1}^{n} n_i^2 d_i} \\ &\underset{\substack{\uparrow \\ (5.5)}}{\geqslant} \min \left(\frac{\sum_{\{i,j\} \in E} (p_i - p_j)^2}{\sum_{i=1}^{n} p_i^2 d_i}, \frac{\sum_{\{i,j\} \in E} (n_i - n_j)^2}{\sum_{i=1}^{n} n_i^2 d_i} \right) \\ &= \min \left(\frac{\sum_{\{i,j\} \in E} (p_i - p_j)^2}{\sum_{i=1}^{n} p_i^2 d_i} \cdot \frac{\sum_{\{i,j\} \in E} (p_i + p_j)^2}{\sum_{\{i,j\} \in E} (p_i + p_j)^2}, \dots \right) \\ &=: \min \left(\frac{Z}{N}, \dots \right). \end{aligned}$$

- Seite 77, Zeile 14:

$$N = \sum_{i=1}^{n} p_i^2 d_i \cdot \sum_{\{i,j\} \in E} (p_i + p_j)^2 \underset{\substack{\uparrow \\ (5.5)}}{\geqslant} \sum_{i=1}^{n} p_i^2 d_i \cdot \sum_{\{i,j\} \in E} 2(p_i^2 + p_j^2)$$

- Seite 78, Zeile 10:

$$\cdots \underset{\substack{\uparrow \\ \text{Teleskop-} \\ \text{summe}}}{=} \Big(\sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \mathbb{1}_E(i,j) \sum_{k=i}^{j-1} \big(p_k^2 - p_{k+1}^2\big) \Big)^2$$

- Seite 79, Zeile 13: Als Letztes wollen wir noch notieren, dass Satz 5.21 zusammen mit Bemerkung 5.17(i) eine obere Schranke für den Eigenwert $\lambda_2(\mathcal{L})$ liefert.

  Korollar 5.22. Sei $G = (V, E)$ ein Graph mit $\deg(i) > 0$ für alle $i \in V$. Dann gilt für den zweitkleinsten Eigenwert λ_2 der normalisierten Laplacematrix von G die Abschätzung $\lambda_2 \leqslant 2$. □

- Seite 84, Zeile −3: *Sei eine Datenmenge* $D = \{x_1, \ldots, x_n\} \subseteq \mathbb{R}^d$ *optimieren, ...*
- Seite 85, Zeile 5:

$$\sum_{j=1}^{k} \|Xv_j\|^2 \geqslant \sum_{j=1}^{k} \|Xw_j\|^2$$

- Seite 85, Zeile −5:

$$\{v_1, \ldots, v_k\} \in \underset{\substack{\{\tilde{v}_1,\ldots,\tilde{v}_k\} \subseteq \mathbb{R}^d \\ \text{Orthonormal-} \\ \text{system}}}{\operatorname{argmax}} \sum_{j=1}^{n} \|X\tilde{v}_j\|^2.$$

- Seite 86, Zeile 16: Sei $D = \{x_1, \ldots, x_n\} \subseteq \mathbb{R}^d$ gegeben und ...
- Seite 86, Zeile 19: sukzessive für $j = 1, \ldots, k$ wählen, wobei ...
- Seite 87, Zeile 5: $\langle w_{k+1}, v_i \rangle = \langle w_{k+1}, \underbrace{v_i - \pi_W(v_i)}_{\perp W} \rangle + \langle w_{k+1}, \underbrace{\pi_W(v_i)}_{\in U} \rangle = 0 + 0 = 0$
- Seite 87, Zeilen 11 und 14: $\cancel{A}X$
- Seite 88, Zeile −11: Sei $D = \{x_1, \ldots, x_n\} \subseteq \mathbb{R}^d$ gegeben und ...
- Seite 88, Zeile −7: ..., falls $r = \dim \operatorname{span} D > 0$. Falls $r = 0$, so sind alle σ_k Null.
- Seite 88, Zeile −5: Für $k \geqslant r + 1$ wenden wir die Gleichung aus dem Beweis von Lemma 6.2 zweimal an. Einerseits auf V_k mit ONB $\{v_1, \ldots, v_k\}$, und andererseits auf V_{k-1} mit ONB $\{v_1, \ldots, v_{k-1}\}$. Durch Umstellen erhalten wir

$$\sigma_k^2 = \|Xv_k\|^2 = \sum_{i=1}^{n} \operatorname{dist}(x_i, V_{k-1})^2 - \sum_{i=1}^{n} \operatorname{dist}(x_i, V_k)^2.$$

  Weil $V_r \subseteq V_{k-1} \subseteq V_k$ gilt, impliziert Lemma 6.4 dass beide Terme auf der rechten Seite verschwinden, also $\sigma_{r+1}, \ldots, \sigma_d = 0$ gilt.

- Seite 89, Zeile −9: Bestimmen Sie, durch Anwendung von Theorem 6.3 in Kombination mit einem Python Paket zur Maximierung unter nichtlinearen Nebenbedinungen, einen 1-bestpassenden Unterraum zu ...
- Seite 91, Zeile 12: ... Singulärwert von A, ...
- Seite 92, Zeile 8: $\|u\|^2 = \|Av\|^2 = \langle Av, Av \rangle = \cdots$
- Seite 95, Zeile 6: Ist $1 \leqslant k < p$ und haben wir $\sigma_{k+1} = \cdots = \sigma_p = 0$, ...
- Seite 96, Zeile −9: $V \in \mathbb{R}^{d \times d}$
- Seite 96, Zeile −8: Dann sind genau r-viele der σ_i ungleich Null. Dies sind die Singulärwere von A ...
- Seite 98, Zeile 6: ..., so erhält man ebenfalls eine Singulärwertzerlegung (beachte, dass man dann zuerst die u_i's erhält und die v_i durch Anwendung von A^{T} entstehen).
- Seite 98, Zeile 8: ... und $\{v_1, \ldots, v_r\}$ irgendein Orthonormalsystem ...
- Seite 98, Zeile 11: Per Konstruktion sind die im Satz angegebenen $v_1, \ldots, v_r$ ein Orthonormalsystem.

- Seite 98, Zeile 20:

$$\|Av\|^2 = \langle v, A^{\mathrm{T}}Av\rangle = \langle v, B\,\mathrm{diag}(\cdots)B^{\mathrm{T}}v\rangle = \langle B^{\mathrm{T}}v, \mathrm{diag}(\cdots)B^{\mathrm{T}}v\rangle = \sum_{j=1}^{r} \lambda_j^{\cancel{2}}(B^{\mathrm{T}}v)_j^2$$

  Im gesamten restlichen Beweis müssen die Quadrate an den Eigenwerten λ_j ebenfalls gestrichen werden!

- Seite 99, Zeile -4: …Nach Lemma 7.3 ist daher v_i ein Eigenvektor von $A^{\mathrm{T}}A$ zum Eigenwert σ_i^2 for $i = 1, \dots, k$.

- Seite 101, Zeile 6: $v = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ \sigma_{k+1} \\ w_{k+1} \end{bmatrix} \Bigg/ \left\| \begin{bmatrix} 0 \\ \vdots \\ 0 \\ \sigma_{k+1} \\ w_{k+1} \end{bmatrix} \right\|$

- Seite 101, Zeile 8: …, wollen wir noch diskutieren in wie fern die Singulärwertzerlegung den Satz über die orthogonale Diagonalisierbarkeit ~~in der Tat~~ verallgemeinert.

- Seite 101, Zeile 11: **Proposition 7.14.** Sei $A \in \mathbb{R}^{n\times n}$ eine symmetrische und positiv semi-definite Matrix, …

- Seite 101, Zeile 22: ~~Multiplikation mit V^{T} von links in~~ Proposition 7.14 liefert also ~~genau~~ eine, wie ganz am Anfang des Kapitels angegebene, orthogonale Diagonalisierung $V^{\mathrm{T}}AV = \mathrm{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0)$; allerdings nur unter der Zusatzannahme, dass A positiv semidefinit ist.

- Seite 102, Zeile 17: $r = \mathrm{rk}\,(A)$

- Seite 104, Zeile 15: *Beweis.* Sei $B \in \mathbb{R}^{n\times d}$ beliebig. Setze

  $V_k := \mathrm{span}\{v_1, \dots, v_k\}$ und $W := \mathrm{span}\{b_1, \dots, b_n\}$~~und $\check{V} := \mathrm{span}\{\check{a}_1, \dots, \check{a}_n\}$,~~

  wobei $b_i \in \mathbb{R}^d$ derjenige Vektor ist, der durch die Einträge der i-ten Zeile von B gegeben ist. Nach Satz 7.12 ist V_k ein k-bestpassender Unterraum für $\{a_1, \dots, a_n\}$. ~~Wir behaupten, dass $\check{V} = V_k$ gilt. Nach Satz 7.17(ii) haben wir $\check{a}_i \in V_k$ für $i = 1, \dots, n$, also $\check{V} \subseteq V_k$. Die Gleichheit folgt dann aus $\dim \check{V} = \mathrm{rk}\,\check{A} = k = \dim V_k$.~~ Wir erhalten ~~damit für jedes $i = 1, \dots, n$ die Abschätzungen~~

$$\begin{aligned}
\|A - B\|_{\mathrm{F}}^2 &= \sum_{i=1}^{n} \|a_i - b_i\|^2 \underset{\substack{\uparrow \\ b_i \in W}}{\geqslant} \sum_{i=1}^{n} \|a_i - \pi_W(a_i)\|^2 \underset{\substack{\uparrow \\ V_k\ k\text{-best} \\ \text{passend für} \\ a_1,\dots,a_n}}{\geqslant} \sum_{i=1}^{n} \|a_i - \pi_{V_k}(a_i)\|^2 \\
&\underset{\substack{\uparrow \\ \text{Satz} \\ 7.17\text{(ii)}}}{=} \sum_{i=1}^{n} \|a_i - \check{a}_i\|^2 = \|A - \check{A}\|_{\mathrm{F}}^2
\end{aligned}$$

  was den Beweis abschließt. □

- Seite 106, Zeile 3: $\forall\, i, j \in \{1, \dots, n\}$: $\big|\|T_{V_k}a_i - T_{V_k}a_j\| - \|a_i - a_j\|\big| \leqslant 2\Big(\sum_{\ell=k+1}^{r} \sigma_\ell\Big)^{1/2}$

- Seite 107, Zeile -1 bis Seite 108, Zeile 1:

$$A = \underbrace{\begin{bmatrix} 0.07 & 0.29 & 0.32 & 0.51 & 0.66 & 0.18 & -0.23 \\ 0.13 & -0.02 & -0.01 & -0.79 & 0.59 & -0.02 & -0.06 \\ 0.68 & -0.11 & -0.05 & -0.05 & -0.24 & 0.56 & -0.35 \\ 0.15 & 0.59 & 0.65 & -0.25 & -0.33 & -0.09 & 0.11 \\ 0.41 & -0.07 & -0.03 & 0.10 & -0.02 & -0.78 & -0.43 \\ 0.07 & 0.73 & -0.67 & 0.00 & -0.00 & 0.00 & 0.00 \\ 0.55 & -0.09 & -0.04 & 0.17 & 0.17 & -0.11 & 0.78 \end{bmatrix}}_{U} \underbrace{\begin{bmatrix} 12.4 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 9.5 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 1.3 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \\ -0.40 & -0.09 & -0.40 & -0.09 & 0.80 \\ \cancel{0.41} & \cancel{0.09} & \cancel{0.40} & \cancel{0.09} & \cancel{0.80} \\ 0.51 & 0.48 & -0.51 & -0.48 & -0.00 \\ 0.48 & -0.51 & -0.48 & 0.51 & -0.00 \end{bmatrix}}_{V^{\mathrm{T}}}$$

$$= \begin{bmatrix} 0.07 & 0.29 & 0.32 \\ 0.13 & -0.02 & -0.01 \\ 0.68 & -0.11 & -0.05 \\ 0.15 & 0.59 & 0.65 \\ 0.41 & -0.07 & -0.03 \\ 0.07 & 0.73 & -0.67 \\ 0.55 & -0.09 & -0.04 \end{bmatrix} \begin{bmatrix} 12.4 & & \\ & 9.5 & \\ & & 1.3 \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \\ -0.40 & -0.09 & -0.40 & -0.09 & 0.80 \end{bmatrix}.$$

- Seite 108, Zeile 5:

$$\check{A} = \begin{bmatrix} 0.15 & 1.97 & 0.15 & 1.97 & 0.56 \\ 0.92 & 0.01 & 0.92 & 0.01 & 0.94 \\ 4.84 & 0.03 & 4.84 & 0.03 & 4.95 \\ 0.36 & 4.03 & 0.36 & 4.03 & 1.20 \\ 2.92 & -0.00 & 2.92 & -0.00 & 2.98 \\ -0.34 & 4.86 & -0.34 & 4.86 & 0.65 \\ 3.92 & 0.02 & 3.92 & 0.02 & 4.00 \end{bmatrix} = \begin{bmatrix} 0.07 & 0.29 \\ 0.13 & -0.02 \\ 0.68 & -0.11 \\ 0.15 & 0.59 \\ 0.41 & -0.07 \\ 0.07 & 0.73 \\ 0.55 & -0.09 \end{bmatrix} \begin{bmatrix} 12.4 & \\ & 9.5 \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \end{bmatrix}$$

- Seite 109, Zeile 16:

$$= \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} 0.07 & 0.29 & \cdots & -0.23 \\ 0.13 & -0.02 & & -0.06 \\ 0.68 & -0.11 & & -0.35 \\ 0.15 & 0.59 & & 0.11 \\ 0.41 & -0.07 & & -0.43 \\ 0.07 & 0.73 & & 0.00 \\ 0.55 & -0.09 & \cdots & 0.78 \end{bmatrix} \begin{bmatrix} 12.4 & & & \\ & 9.5 & & \\ & & 1.3 & \\ & & & \ddots \end{bmatrix} \begin{bmatrix} 0.56 & 0.09 & 0.56 & 0.09 & 0.59 \\ -0.12 & 0.69 & -0.12 & 0.69 & 0.02 \\ \vdots & & & & \vdots \\ 0.48 & -0.51 & -0.48 & 0.51 & 0.00 \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

- Seite 109, Zeile -2:

$$u_2 = \quad 0.29 \cdot \text{Antje} - 0.02 \cdot \text{Birgit} + \cdots - 0.09 \cdot \text{Gül},$$

- Seite 111, Zeile 12:

$$\begin{array}{r} \text{Antje} \\ \text{Birgit} \\ \text{Constanze} \\ \text{Dorothee} \\ \\ \\ \text{Eleonore} \\ \text{Fatema} \\ \text{Gül} \end{array} \quad \check{A} = \begin{bmatrix} \boxed{0.07 \quad 0.29} \\ \boxed{0.13 \quad -0.02} \\ \boxed{0.68 \quad -0.11} \\ \boxed{0.15 \quad 0.59} \\ \boxed{0.41 \quad -0.07} \\ \boxed{0.07 \quad 0.73} \\ \boxed{0.55 \quad -0.09} \end{bmatrix} \begin{bmatrix} 12.4 & \\ & 9.5 \end{bmatrix} \begin{array}{c} \begin{array}{ccccc} \text{Alien} & \text{Casablanca} & \text{Star Wars} & \text{Titanic} & \text{Matrix} \end{array} \\ \begin{bmatrix} \boxed{\begin{matrix} 0.56 \\ -0.12 \end{matrix}} & \boxed{\begin{matrix} 0.09 \\ 0.69 \end{matrix}} & \boxed{\begin{matrix} 0.56 \\ -0.12 \end{matrix}} & \boxed{\begin{matrix} 0.09 \\ 0.69 \end{matrix}} & \boxed{\begin{matrix} 0.59 \\ 0.02 \end{matrix}} \end{bmatrix} \end{array}$$

- Seite 110, Zeile 7: $\mathbb{R}^5_{\mathcal{F}}$
- Seite 112, Zeile 1: ... und $\check{\mathcal{V}} = \{v_1, v_2\}$ ...
- Seite 112, Zeile 5: $(\text{Film})_{\mathcal{F}} \quad \mathbb{R}_{\mathcal{F}} \xrightarrow{A} \mathbb{R}_{\mathcal{B}} \quad (\text{Bewerterin})_{\mathcal{B}}$
- Seite 111, Zeile 4: R (statt R)
- Seite 112, Zeilen 14 und 25: R (statt R)
- Seite 112, Zeile -3: ... die Daten ~~erst~~ einem geeigneten Pre- oder Postprocessing zu unterziehen ...
- Seite 122, Zeile 1 in eq. (8.2): $V(\|X\|^2) = V(X_1^2) + \cdots + V(X_d^2)$.
- Seite 122, Zeile 3 in Gleichung (8.2): $d \cdot \left(\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^4 \exp(-x^2/2)\,\mathrm{d}x - \mathrm{V}(X_1)^2\right)$
- Seite 123, Zeile 13: erhalten wir $\mathrm{E}(S_d) = 0$
- Seite 123, Zeile -5: $= 2\sqrt{d}\,\mathrm{E}(\|X\| - \sqrt{d}\,)$
- Seite 124, Zeile 8: **Satz 8.2.** Seien $X, Y \sim \mathcal{N}(0, 1, \mathbb{R}^d)$ unabhängig. Dann gelten
  (i) $\forall\, d \in \mathbb{N}$: $\left|\,\mathrm{E}(\|X - Y\| - \sqrt{2d}\,)\right| \leqslant \sqrt{2/d}$,
- Seite 124, Zeile 10: *(ii)* $\forall\, d \in \mathbb{N}$: $\mathrm{V}(\|X - Y\|) \leqslant 4$.
- Seite 125, Zeile -3: H_d~~(1)~~
- Seite 125, Zeile -6: *(i)* $\forall\, d \in \mathbb{N}$: $\left|\,\mathrm{E}(\|X - Y\| - \sqrt{2d}\,)\right| \leqslant \sqrt{2/d}$,
- Seite 127, Zeile -5: *(ii)* $\forall\, d \in \mathbb{N}$: $\mathrm{V}(\|X - Y\|) \leqslant 4$.
- Seite 127, Zeile -4: Berechnen Sie zuerst $\mathrm{V}((X_i - Y_i)^2) = 8$ ...
- Seite 127, Zeile -3: Folgern Sie dann $\mathrm{V}((X_i - Y_i)^2) = 8d$.
- Seite 129, Zeile -1: $0 < \varepsilon < 1$
- Seite 131, Zeile 9: $H_{\delta,x_1} = \left\{(x_2, \ldots, x_d \in \mathbb{R}^{d-1} \;\middle|\; (x_1, x_2, \ldots, x_d) \in H_\delta\right\}$
- Seite 134, Zeile 9: Für solche Zufallsvektoren erhält man ...
- Seite 139, Zeile -1: $\|X^{(i)}\| \approx 1$
- Seite 142, Zeile -7: *Beweis.* Wir setzen $Y_1 + \cdots + Y_d$ und ...

- Seite 142, letzer Ausdruck in Gleichung (10.1): $= \mathrm{e}^{-ta} \prod_{i=1}^{d} \mathrm{E}(\mathrm{e}^{tY_i})$
- Seite 145, Zeilen $4-8$:

$$\begin{aligned}
\mathrm{P}\big[\,\big|\|X\| - \sqrt{d}\,\big| > \varepsilon\big] &\leqslant \mathrm{P}\big[\,\big|\|X\| - \sqrt{d}\big| \cdot (\|X\| + \sqrt{d}) \geqslant \varepsilon \cdot \sqrt{d}\big] \\
&= \mathrm{P}\big[\,\big|X_1^2 + \cdots + X_d^2 - d\big| \geqslant \varepsilon\sqrt{d}\big] \\
&= \mathrm{P}\big[\,\big|(X_1^2 - 1) + \cdots + (X_d^2 - 1)\big| \geqslant \varepsilon\sqrt{d}\big] \\
&= \mathrm{P}\big[\,\big|\tfrac{X_1^2-1}{2} + \cdots + \tfrac{X_d^2-1}{2}\big| \geqslant \tfrac{\varepsilon\sqrt{d}}{2}\big] \\
&= \mathrm{P}\big[\,\big|Y_1 + \cdots + Y_d\big| \geqslant a\big],
\end{aligned}$$

- Seite 145, Zeile 12: 1 Die Y_i sind ~~paarweise~~ unabhängig nach Fakt 10.1(i).
- Seite 146, Zeile 5: $\mathrm{P}\big[\,\big|\|X\| - \sqrt{d}\,\big| \geqslant \varepsilon\big]$
- Seite 154, Zeile -10:

$$\mathrm{P}\left[\,\left|\left\langle \frac{u_i}{\|u_i\|}, \frac{u_j}{\|u_j\|} \right\rangle\right| \leqslant \varepsilon\right] \geqslant 1 - \frac{2/\varepsilon + 7}{\sqrt{d}}.$$

- Seite 157, Zeile 2ff:

$$\begin{aligned}
\mathrm{P}\big[\cdots\big] &= 1 - \mathrm{P}\big[\,\exists\, i \neq j \colon \|T_U x_i - T_U x_j\| \notin \big((1-\varepsilon)\|x_i - x_j\|, (1+\varepsilon)\|x_i - x_j\|\big)\big] \\
&\geqslant 1 - \sum_{i \neq j} (1 - P_{ij}) \geqslant 1 - \sum_{i \neq j} 2\,\mathrm{e}^{-k\varepsilon^2/16} \geqslant 1 - \frac{n^2}{2} \cdot 2\,\mathrm{e}^{-k\varepsilon^2/16} \\
&\geqslant 1 - n^2\,\mathrm{e}^{-(\frac{48}{\varepsilon^2}\log n)\,\varepsilon^2/16} = 1 - n^2\,\mathrm{e}^{\log(n^{-3})} \\
&= 1 - \frac{1}{n}
\end{aligned}$$

- Seite 164, Zeile -17: …der Abstand der Mittelpunkte, …
- Seite 167, Zeile 5–7: ~~Im Fall der Varianz sind diese eher technisch, und wir formulieren daher im Satz für die Varianz nur die sich ergebende qualitative asymptotische Aussage.~~
- Seite 172, Zeile 5: $\sqrt{(\Delta(d))^2 + 2d} - \sqrt{2d} \to \infty$
- Seite 173, Zeile 4: $\lim_{d\to\infty} \sqrt{(\Delta(d))^2 + 2d} - \sqrt{2d} = \infty$
- Seite 173, Zeile 8: $\sqrt{(\Delta(d))^2 + 2d} - \sqrt{2d} \geqslant \sqrt{R\sqrt{d} + 2d} - \sqrt{2d} \xrightarrow{d\to\infty} \frac{R}{2\sqrt{2}}$
- Seite 173, Zeile 9: Multiplikation mit $\sqrt{(\Delta(d))^2 + 2d} + \sqrt{2d}$ …
- Seite 173, Zeile 10: $\cdots \geqslant R \cdot \big(\sqrt{(\Delta(d))^2 + 2d} - \sqrt{2d}\big) \geqslant \cdots$
- Seite 183, Zeile -1: Wenn D linear trennbar ist, …
- Seite 186, Zeile 8: ___ **return** $w^{(j)}$
- Seite 186, Zeile -6: $y_i\langle w^{(j+1)}, \widehat{x}_i\rangle = y_i\langle w^{(j)} + y_i\widehat{x}_i, \widehat{x}_i\rangle = \underbrace{y_i\langle w^{(j)}, \widehat{x}_i\rangle}_{\text{fälschlicherweise kleiner Null}} + \underbrace{y_i^2\langle \widehat{x}_i, \widehat{x}_i\rangle}_{\text{Addition eines positiven Korrekturterms}}.$
- Seite 187, Zeile 19: Da D linear trennbar ist, existiert irgendein $w \in \mathbb{R}^{d+1}\backslash\{0\}$, sodass alle Punkte korrekt klassifiziert werden. ~~Dieser Vektor w kann nicht der Nullvektor sein, denn dann wäre $h \equiv 0$ und alle Datenpunkte würden falsch klassifiziert.~~
- Seite 187, Zeile -3: $\langle w^*, w^{(j+1)}\rangle \geqslant \langle w^*, w^{(0)}\rangle + (j+1)\cdot\gamma = (j+1)\cdot\gamma$
- Page 188, Zeile 1: unter der geschweiften Klammer: $\leqslant 0$, weil …
- Seite 188, Zeile 3: $\|w^{(j+1)}\|^2 \leqslant \|w^{(0)}\|^2 + (j+1)\cdot R^2 = (j+1)\cdot R^2$.
- Seite 187, Zeile 5: $(j+1)\cdot\gamma\langle w^*, w^{(j+1)}\rangle \leqslant \|w^*\|^{\cancel{2}}\|w^{(j+1)}\|^{\cancel{2}} = \|w^{(j+1)}\|^{\cancel{2}} + \sqrt{j+1}\cdot R$
- Seite 189, Zeile -5: $(x, y) \in D$

- Seite 190, Zeile 14–15: … die Worte „Bonus“, „Vertrag“, „das“ und „Mensa“ …
- Seite 193, Zeile 6: $\cdots = \big\langle w', x_0 - (\langle w', x_0\rangle + b')w' \big\rangle + b'$
- Seite 193, Zeile 12: $\geqslant \|x_0 - x_1\|^2 + 2\big\langle (\langle w', x_0\rangle + b')w', x_1 - x\big\rangle$
- Seite 193, Zeile 13: $= \|x_0 - x_1\|^2 + 2(\langle w', x_0\rangle + b')\langle w', x_1 - x\rangle$
- Seite 194, Zeilen -2 und -1: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 194, Zeile -1: $h\colon \mathbb{R}^d \to \mathbb{R}^{\cancel{d}}$
- Seite 195, Zeilen 2, 4, 5, 9, 10, 12, 15 und 20: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 196, Zeilen 6–8, 12 und 13: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 198, Zeile 6: $(w^*, b^*) \in M$
- Seite 198, Zeile 11–16: Es folgt also nach Proposition 17.14, dass $w_1^* = w_2^* =: w^*$ ist. Gelte ohne Einschränkung $b_1^* < b_2^*$. Dann wählen wir für ~~(w^*, b_1^*) und~~ (w^*, b_2^*) ~~jeweils i_1 und~~ einen Index i wie in Teil ② und erhalten

$$y_i(\langle w^*, x_i\rangle + b_1^*) = \langle w^*, x_i\rangle + b_1^* < \langle w^*, x_i\rangle + b_2^* = 1$$

  im Widerspruch dazu, dass (w^*, b_1^*) in M liegt. ~~Ist $b_1^* > b_2^*$, so vertauschen wir die Rollen von i_1 und i_2.~~
- Seite 198, Zeile -11, -8 und -4: $\mathcal{R}(D)$, $\mathcal{K}(D)$
- Seite 199, Zeile 13: … über die im Satz angegebene Menge zu minimieren, …
- Seite 200, Zeile 7: $L(x, \theta, \mu) := f(x) - \sum_{i=1}^{q} \theta_i g_i(x) + \cancel{\mu} \sum_{j=r}^{q} \mu_i h_j(x)$
- Seite 200, Zeile 18: …, ist x^* ein Minimierer des oben angegebenen Optimierungsproblems …
- Seite 203, Zeile 17: … ist es möglich, i_0 mit $\lambda_{i_0} \neq 0$ …
- Seite 206, Zeile 7: $D_1 = \{(x_i, y_i) \mid i = 1, 6, 7\}$ und $D_2 = \{(x_i, y_i) \mid i = 1, 6, 11\}$
- Seite 206, Zeile 8: Durch Streichen von Nullen in Beispiel 14.15(i) und Lösung des Optimierungsproblems für D_2 erhalten wir …
- Seite 206, Zeile 12: ~~0.349~~ 0.439
- Seite 207, Zeile 4 (in den Bildern): $D_1 \cdots D_2$
- Seite 207, Zeilen 12 und 13: $\lambda_i^\star$
- Seite 208, Zeile 13: … und Satz 14.12(ii) ist [GK02, Satz 2.46].
- Seite 209, Zeile -6: …, wenn man einen der Punkte x_6^*, x_7^*, oder x_{11}^* weglässt?
- Seite 216, Zeile -14: …, sodass $y_i(\langle w, x_i\rangle + b) \geqslant 1$ für ….
- Seite 220, Zeile 16: … mit $\lambda_{i_0}^* \neq 0$ ist …
- Seite 220, Zeile 18: … Wahl von λ^* und …
- Seite 224, Zeile 6: Haben wir also $\langle f, f\rangle = 0$ ~~für alle $x \in X$~~, so ist …
- Seite 224, Zeile -10: … positive Semidefinitheit der Gram-Matrix …
- Seite 226, Zeile 12: Geben Sie an, welche $x \in \mathbb{R}$ vom zurückgezogenen Klassifizierer …
- Seite 230, Zeile 15: die *Rectified Linear Unit*
- Seite 231, Zeile -4: … Neuronen aus Proposition 16.2 zusammensetzen
- Seite 231, Zeile 12:

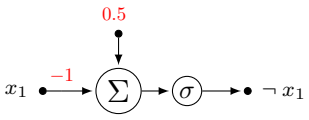

- Seite 231, Zeile -3:

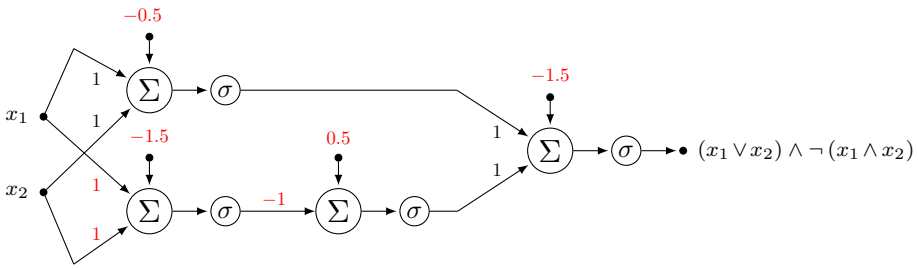

- Seite 232, Zeile 3: …sonst,
- Seite 232, Zeile 6–7: …ist es manchmal von Vorteil …
- Seite 233, Zeile 14: Alternativ erhält man mit Sigmoid-Aktivierung, …
- Seite 233, Zeile −5: $N = \begin{bmatrix} a_{11} & \cdots & a_{1\ell} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{m\ell} \end{bmatrix} \begin{bmatrix} n_1 \\ \vdots \\ n_\ell \end{bmatrix}$
- Seite 233, Zeile −4: …und eine Matrix $(a_{ij})_{i,j} \in \mathbb{R}^{m\times\ell}$ …
- Seite 236, Zeile 9: B ist die Matrix ohne das $(\cdot)^{-1}$.
- Seite 239, Zeile 15: $\mathcal{F}(f_1 * f_2) = \mathcal{F}f_1 \cdot \mathcal{F}f_2$
- Seite 241, Zeile 10: $\forall\, w \in \mathbb{R}^{\cancel{n}},\ b \in \mathbb{R}\colon \displaystyle\int_\Omega \sigma(wx+b) + \ell \,\mathrm{d}\mu(x) = 0$
- Seite 241, Zeile −5: $\forall\, w \in \mathbb{R}^{\cancel{n}},\ b \in \mathbb{R}\colon \displaystyle\int_\Omega \sigma(wx+b) \,\mathrm{d}\mu(x) = 0$
- Seite 246, Zeile 3: Da Ω kompakt ist, existiert $c_0 \geqslant 0$ mit $a_1 f_1 + \cdots + a_i f_i + c_0 \geqslant 0$ auf Ω für alle $i = 1, \ldots, \ell$. Wir konstruieren …
- Seite 252, Line 7: …folgt zunächst die erste Ableitung. Um die beiden anderen einzusehen, benutzen wir …
- Seite 262, Zeile 1–4: Den Rieszschen Darstellungssatz in der Version 16.19 kann man in [Wer18, Theorem II.2.5] nachlesen, die andere Version 16.16, oft auch Riesz-Markov-Theorem genannt, findet man in [Rud87, Theorem 6.19].
- Seite 270, Zeile 14: Dann gilt $h'(t) = \langle \nabla f(y + t(x-y)), x-y\rangle$ …
- Seite 270, Zeile 16: $\cdots = \displaystyle\int_0^1 \langle \nabla f(y+t(x-y)), x-y\rangle \,\mathrm{d}t$
- Seite 270, Zeile 18: $\cdots = \displaystyle\int_0^1 \langle \nabla f(y+t(x-y)), x-y\rangle - \langle f(y), x-y\rangle \,\mathrm{d}t$
- Seite 270, Zeile −1: …mithilfe von Proposition 17.4 …
- Seite 271, Zeile 14: **Folgerung 17.10.** Sei $f\colon \mathbb{R}^n \to \mathbb{R}$ differenzierbar ~~und konvex~~.
- Seite 271, Zeile 18–19: (i)$\Longrightarrow$(ii): Aus der Konvexität folg die erste Ungleichung mit Proposition 17.4 und …
- Seite 271, Zeile 20: (ii)$\Longrightarrow$(i): Die erste Ungleichung impliziert Konvexität mit Propsition 17.4 und …
- Seite 272, Zeile 16: Aus Lemma 17.9 und Proposition 17.4 folgern wir
- Seite 272, Zeile 20: $\underset{\substack{\uparrow \\ \text{Prop. } 17.4}}{\geqslant}$
- Seite 273, Zeile 10: $\underset{\substack{\uparrow \\ \text{Prop. } 17.4}}{\leqslant}$
- Seite 275, Zeile −2: Dann gilt ~~wegen~~
- Seite 277, Zeile −10: mit Proposition 17.4
- Seite 278, Zeile 8: Dies ist nach Proposition 17.4 äquivalent zu
- Seite 278, Zeile 18: Ein Vergleich der Abschätzung in Proposition 17.4 zeigt nochmal …

- Seite 279, Zeile 13: $\underset{\substack{\uparrow \\ \text{Lem. 17.18 u.} \\ \text{Prop. 17.4}}}{\geqslant}$
- Seite 283, Zeile −9: 4: $x^{(k+1)} \leftarrow x^{(k)} - \gamma_k \nabla f(x^{(k)})$.
- Seite 286, Zeile 6: (ii) Für A, $B \in \Sigma$ mit $\mathrm{P}(B) \neq 0$ heißt $\mathrm{P}(A|B) := \dfrac{\mathrm{P}(A \cap B)}{\mathrm{P}(B)}$
- Seite 287, Zeile 19:

$$\rho(x) = \tfrac{1}{(2\pi\sigma^2)^{d/2}}\, \mathrm{e}^{-\frac{\|x-\mu\|^2}{2\sigma^2}} \quad \text{bzw.} \quad \rho(x) = \tfrac{1}{\lambda^d(B)} \cdot \mathbb{1}_B(x),$$

- Seite 290, Zeile −5: Für $A = A_1 \times \cdots \times A_d \subseteq \mathbb{R}^d$ mit $A_i \in \mathcal{B}^{\cancel{d}}$ berechnen wir
- Seite 292, Zeile 2:

$$\begin{aligned}
(\rho_1 * \rho_2)(s) &= \frac{1}{2\pi\sqrt{ab}} \int_{\mathbb{R}} \exp\Big(-\frac{(s-t)^2}{2a}\Big) \exp\Big(-\frac{t^2}{2b}\Big)\, \mathrm{d}t \\
&= \frac{1}{2\pi\sqrt{ab}} \int_{\mathbb{R}} \exp\Big(-\frac{b(s^2-2st+t^2)+at^2}{2ab}\Big)\, \mathrm{d}t \\
&= \frac{1}{2\pi\sqrt{ab}} \int_{\mathbb{R}} \exp\Big(-\frac{t^2(b+a)-2stb+bs^2}{2ab}\Big)\, \mathrm{d}t \\
&= \frac{1}{2\pi\sqrt{ab}} \int_{\mathbb{R}} \exp\Big(-\frac{t^2(b+a)/c-2stb/c+bs^2/c}{2ab/c}\Big)\, \mathrm{d}t \\
&= \frac{1}{\sqrt{2\pi c}\sqrt{2\pi(ab/c)}} \int_{\mathbb{R}} \exp\Big(-\frac{(t-(bs)/c)^2-(sb/c)^2+s^2(b/c)}{2ab/c}\Big)\, \mathrm{d}t \\
&= \frac{1}{\sqrt{2\pi c}} \exp\Big(+\frac{(sb/c)^2-s^2(b/c)}{2ab/c}\Big) \frac{1}{\sqrt{2\pi(ab/c)}} \int_{\mathbb{R}} \exp\Big(-\frac{(t-(bs)/c)^2}{2ab/c}\Big)\, \mathrm{d}t \\
&= \frac{1}{\sqrt{2\pi c}} \exp\Big(+\frac{(sb/c)^2c^2-s^2(b/c)c^2}{2abc}\Big) \\
&= \frac{1}{\sqrt{2\pi c}} \exp\Big(+\frac{s^2(b^2-bc)}{2abc}\Big) \\
&= \frac{1}{\sqrt{2\pi c}} \exp\Big(-\frac{s^2}{2c}\Big),
\end{aligned}$$

- Seite 296, Zeile −14: S. Shalev-Shwartz und S. Ben-David, Understanding